

Universidad Mariano Gálvez de Guatemala
Centro Universitario de Puerto Barrios
Facultad de Ingeniería en Sistemas
Proyecto de Graduación II
Ing. Juan Pablo Escobar



Doble prueba de calidad del Sprint 1.

Auditoria ciega e independiente del incremento, ejecutada por dos revisores sobre el commit 713da5a del proyecto BayStream.

Carlos Giovanni Martínez Aldana 0909-22-19157

Puerto Barrios, Izabal 29 de agosto de 2026

Índice

I. Introducción

A. Propósito del documento

Este documento reporta el resultado de una auditoría de calidad ejecutada sobre el Incremento 1 del proyecto BayStream mediante un diseño de doble revisión ciega. Dos auditores independientes respondieron por separado un mismo instrumento de 78 comprobaciones, sin conocer las respuestas del otro, y sus resultados se contrastaron posteriormente.

La finalidad no es únicamente enumerar defectos. Un informe de calidad que presenta una lista de hallazgos sin declarar cómo se obtuvieron es difícil de refutar y, por lo mismo, de poco valor probatorio. Este documento adopta el compromiso contrario: declara el instrumento antes de aplicarlo, expone el grado de concordancia entre los dos revisores, documenta las nueve discrepancias una por una —incluidas las tres en que el primer auditor se equivocó— y cuantifica cuánto aportó cada mitad del método.

El ejercicio se realizó el 27 de agosto de 2026 sobre el commit 713da5a, que corresponde al cierre del Sprint 1.

B. Definición de términos

Se definen operacionalmente los términos empleados a lo largo del informe, de modo que su interpretación no dependa del criterio del lector.

Tabla 60.

Definición de términos del informe de doble prueba

Término	Definición operacional
Doble prueba ciega	Diseño de verificación en el que dos auditores responden un mismo instrumento de forma independiente y sin acceso a las respuestas del otro. La concordancia entre ambos mide la fiabilidad del resultado; las discrepancias señalan los puntos que un revisor único habría dado por buenos.
Comprobación estática	Verificación que se resuelve leyendo el código fuente, sin compilar ni ejecutar. Se identifica con la marca [E] y la respondieron los dos auditores.
Comprobación dinámica	Verificación que exige compilar, ejecutar la aplicación o inspeccionar su salida. Se identifica con la marca [D] y solo pudo responderla el auditor con acceso a la cadena de herramientas de Flutter.
Veredicto	Resultado asignado a cada comprobación: CUMPLE, CUMPLE CON RESERVA, NO CUMPLE o NO DETERMINABLE. Este último es una respuesta válida y preferible a una conjetura cuando las herramientas disponibles no permiten decidir.
Defecto confirmado	Comprobación en la que ambos auditores emitieron el veredicto NO CUMPLE de forma independiente. Es la categoría de mayor confianza del informe.
Hallazgo latente	Defecto real del código que, verificado contra los datos de producción, no se manifiesta hoy. Se distingue del defecto activo para no sobredimensionar el riesgo.
Corpus A01	Archivo BAPLIE real anonimizado empleado como caso de prueba: 164-310 bytes, 977 contenedores y 27 bahías. Sus cifras se verificaron por conteo directo de segmentos EDI, sin intervención de la aplicación.

Fuente: elaboración propia.

C. Limitaciones del informe

Cuatro limitaciones acotan el alcance de lo que aquí se afirma, y conviene declararlas antes de presentar los resultados.

- La auditoría es una revisión de calidad sobre un incremento acotado. No constituye una certificación de calidad del producto ni sustituye a las tareas de cierre previstas para octubre (TC-01 a TC-05).
- El primer auditor no dispuso de la cadena de herramientas de Flutter y no pudo compilar, ejecutar ni capturar la aplicación. Once de sus respuestas quedaron en NO DETERMINABLE por esa razón, declarada por adelantado.
- El segundo auditor no dispuso de acceso a la consola de Firebase, por lo que una comprobación quedó sin responder por ninguno de los dos y corresponde al autor del proyecto.
- La validación dinámica se ejecutó sobre un único archivo BAPLIE real anonimizado. Varios de los defectos identificados no se manifiestan con ese archivo y se reportan explícitamente como latentes.

II. Método

A. Diseño de la doble revisión

El diseño responde a una debilidad conocida de la revisión por un solo auditor: quien redacta el criterio de verificación tiende a leer el código buscando confirmarlo. En la evaluación de seguridad previa del proyecto, dos hallazgos resultaron falsos precisamente por haber inferido el comportamiento de un componente en vez de observarlo.

Para mitigarlo se construyó un instrumento común y se encargó su respuesta a dos auditores con capacidades distintas, que trabajaron sin contacto. El contraste posterior produce tres clases de información: las coincidencias, que elevan la confianza en un hallazgo; las discrepancias, que localizan los puntos donde un revisor único se habría equivocado; y el conjunto de comprobaciones que solo uno pudo responder, que mide el aporte marginal de su capacidad específica.

B. Garantías de independencia

La ceguera se aseguró por dos mecanismos de naturaleza distinta, uno verificable y otro de aislamiento.

- **Orden de confirmaciones.** El informe del primer auditor quedó congelado en el commit 886280b antes de que el segundo comenzara. El historial del repositorio prueba que no fue ajustado después de conocer el resultado ajeno.
- **Aislamiento del área de trabajo.** El segundo auditor trabajó en un árbol de trabajo separado, anclado al commit 713da5a, donde el archivo del primero no existe. La independencia no dependió de que respetara una instrucción.

La combinación es relevante porque los dos mecanismos protegen contra riesgos distintos: el primero impide la revisión retrospectiva del propio informe, y el segundo impide el acceso al ajeno.

C. Instrumento de verificación

El instrumento consta de 78 comprobaciones distribuidas en ocho bloques, cada una marcada como estática o dinámica. La regla de respuesta exige citar archivo y número de línea: no se admite el veredicto CUMPLE apoyado en la bitácora del sprint, porque una afirmación del proyecto no constituye evidencia de sí misma.

Tabla 61.

Distribución de las comprobaciones del instrumento por bloque

Bloque	Objeto de verificación	Est.	Din.	Total
1	RF-012 · Indicadores de peso por nivel	7	2	9
2	RF-020 · Estado vacío por frecuencia	5	2	7
3	RF-025 · Exportación de reporte en PDF	11	6	17
4	RF-026+ · Perfil longitudinal del buque	7	3	10
5	RF-033 · Exportación en CSV y JSON	7	3	10
6	Robustez del analizador BAPLIE	8	2	10
7	T-22 y T-23 · Reglas de Firestore	4	1	5
8	Pruebas, arquitectura y compilación	6	4	10
	Total	55	23	78

Fuente: elaboración propia, a partir de CHECKLIST-DOBLE-PRUEBA-SPRINT1.md.

D. Asimetría de capacidades entre auditores

Los dos auditores no dispusieron de las mismas herramientas, y esa asimetría es deliberada: es lo que permite medir el aporte de la verificación dinámica. Se documenta porque condiciona la interpretación de los resultados.

Tabla 62.

Capacidades disponibles para cada auditor

Capacidad	Auditor 1	Auditor 2
Lectura del código fuente	Sí	Sí
Compilación en las tres plataformas	No	Sí
Ejecución de la suite de pruebas	No	Sí
Ejecución de la aplicación y captura	No	Sí

Capacidad	Auditor 1	Auditor 2
Análisis estático de la herramienta	No	Sí
Conteo directo sobre el corpus EDI	Sí	Sí
Acceso a la consola de Firebase	No	No

Fuente: elaboración propia. La ausencia de la cadena de herramientas de Flutter en el entorno del primer auditor se verificó antes de iniciar la auditoría y no se supuso.

III. Resultados

A. Concordancia entre auditores

De las 78 comprobaciones del instrumento, 55 son estáticas y las respondieron los dos auditores. Una de ellas admite respuesta en prosa y no en veredicto, por lo que la comparación estricta se establece sobre 54 juicios técnicos.

Tabla 63.

Concordancia entre los dos auditores sobre las comprobaciones comparables

Resultado	Cantidad	Proporción
Veredicto idéntico	45	83 %
Discrepancia de grado o etiqueta	4	7 %
Discrepancia de fondo	5	9 %
Total comparable	54	100 %

Fuente: elaboración propia.

Una concordancia del 83 % entre dos revisores que no se consultaron, sobre medio centenar de juicios técnicos, indica que el instrumento es interpretable de forma consistente. Las nueve discrepancias, sin embargo, concentran el valor del ejercicio y se analizan en detalle más adelante.

B. Defectos confirmados por dos vías independientes

Quince comprobaciones recibieron el veredicto NO CUMPLE de ambos auditores por separado. Constituyen la categoría de mayor confianza del informe: dos revisores, dos métodos y ningún contacto entre ellos.

Tabla 64.

Defectos identificados de forma independiente por los dos auditores

ID	Defecto confirmado
1.7	La cabecera de filas del plano de bahía se desalinea progresivamente respecto de las columnas que rotula
3.2	El reporte en PDF no reproduce el esquema cromático de la pantalla en las etiquetas de cubierta y bodega ni en la leyenda
3.8	El PDF omite la columna de peso por nivel y su alerta de sobrepeso
3.9	La rejilla del PDF y la de pantalla se generan con lógicas distintas
3.11	La portada del PDF no muestra los puertos del viaje, porque los campos correspondientes nunca se asignan
4.4	El texto del perfil longitudinal emplea un único color sobre toda la escala, sin contraste garantizado en ambos extremos
4.7	La ocupación se calcula contra una capacidad fija y no contra la geometría real de cada bahía
5.4	La exportación en CSV no neutraliza los prefijos de fórmula, exponiendo la hoja de cálculo a la debilidad CWE-1236
6.3	El analizador no impone límite de tamaño, de segmentos ni de contenedores
6.4	La decodificación del archivo no interpreta UTF-8 real
6.5	Un archivo binario o sin separador produce un diagnóstico que no describe el problema del usuario

ID	Defecto confirmado
6.6	Existen rutas de análisis que descartan contenedores sin aviso
6.7	El análisis del archivo se ejecuta en el hilo de interfaz
6.8	El texto original de las excepciones alcanza la interfaz de usuario
8.3	Existen pruebas que se superarían igualmente con el código defectuoso

Fuente: elaboración propia, a partir del contraste de los dos informes de auditoría.

El bloque 6 completo —las ocho comprobaciones sobre el analizador BAPLIE— obtuvo veredictos idénticos. Ese resultado obliga a matizar la valoración registrada en la evaluación de seguridad previa, que calificaba la validación de entrada como control adecuado: la afirmación es exacta en el plano sintáctico, donde no se halló una sola conversión numérica sin protección ni un acceso por índice sin guarda en 836 líneas, y deja de serlo en el control de recursos, la decodificación y el diagnóstico.

C. Discrepancias y su resolución

Las nueve discrepancias se resolvieron releando el código. Cinco resultaron de fondo y cuatro de mera clasificación, cuando ambos auditores describían el mismo comportamiento y lo situaban en categorías distintas.

Tabla 65.

Discrepancias entre auditores y veredicto adoptado tras el contraste

ID	Auditor 1	Auditor 2	Adoptado	Razón de la resolución
1.2	Reserva	No cumple	No cumple	La prueba construye el caso que rompería la igualdad, pero sin peso, de modo que la aserción se satisface por vacío
7.4	Cumple	Reserva	Reserva	La creación de documentos permanece abierta: la regla impide alterar una medición pero no sembrar una falsa
8.4	Cumple	No cumple	No cumple	La capa de presentación importa implementaciones de la capa de datos y no solo la abstracción del dominio
4.3	No cumple	Reserva	Reserva	El caso es real pero no se dispara con los datos de producción; se reclasifica como latente
3.4	Reserva	Cumple	Cumple	La ejecución aportó la evidencia que la lectura no podía dar
1.3	Cumple	Reserva	Reserva	Diferencia de clasificación
2.4	Cumple	Reserva	Reserva	Diferencia de clasificación
3.10	Cumple	Reserva	Reserva	Diferencia de clasificación
4.5	Cumple	Reserva	Reserva	Diferencia de clasificación

Fuente: elaboración propia.

Las tres primeras discrepancias merecen atención particular porque en las tres el primer auditor emitió un veredicto más benigno que el correcto, y el defecto solo salió a la luz por la existencia de un segundo revisor.

1. La prueba que aparenta cubrir un caso sin cubrirlo

La condición de terminado de la tarea de peso por nivel exige que la suma de los pesos por nivel iguale el peso total de la bahía. La prueba unitaria correspondiente construye deliberadamente un contenedor sin

posición de estiba —el único caso capaz de romper esa igualdad— y lo incorpora a la bahía. Sin embargo, ese contenedor se define sin peso bruto, de modo que aporta cero a ambos lados de la comparación y la aserción se satisface sin ejercitar el caso.

El defecto es de una clase particularmente costosa: no es la ausencia de una prueba, sino la presencia de una que aparenta cubrir el caso exacto y no lo cubre. Un revisor único que localice la prueba y verifique que el caso está contemplado dará el punto por satisfecho. Basta asignar un peso a ese contenedor para que la prueba falle.

2. El alcance real de la regla de integridad de las mediciones

La regla de autorización que protege la instrumentación de la hipótesis H5 permite exclusivamente la transición de una medición abierta a una cerrada, y únicamente sobre dos campos. El primer auditor la calificó de garantía de inmutabilidad para los campos que definen la medición.

El segundo auditor señaló que la creación de documentos permanece sin restricción. La consecuencia es que la regla impide alterar una medición existente, pero no impide crear una medición nueva con valores arbitrarios. Para un instrumento de medición de tesis la distinción es material, y el argumento de integridad debe enunciarse con esa precisión y no con mayor alcance del que tiene. Su resolución se traslada a TC-03.

D. Hallazgos exclusivos de la verificación dinámica

Las 23 comprobaciones dinámicas miden el aporte de poder ejecutar el producto. Tres resultados de ese conjunto no eran alcanzables por ningún análisis de código.

El primero y de mayor consecuencia: la vista de plano de bahía, cargada con el corpus real en Android API 36, produce una detención persistente de la aplicación que no se recupera al solicitar la espera. Las mismas operaciones sobre Windows y sobre navegador se completan sin incidente. La comprobación correspondiente pasa a NO CUMPLE: no puede afirmarse que la funcionalidad opere en los tres clientes soportados.

El segundo: el corpus real contiene únicamente dos líneas navieras y tres puertos de descarga. En consecuencia, el criterio de aceptación que exige mostrar las cinco navieras más frecuentes no puede demostrarse con ese archivo, porque no existen cinco. La limitación es del conjunto de datos y no del código.

El tercero: las mediciones de tiempo, inexistentes hasta ahora. La generación del reporte en PDF requirió 5,46 segundos en la primera ejecución y 1,47 en la siguiente; la carga y análisis del corpus, 3,11 segundos, sin que el indicador de progreso llegara a mostrarse, lo cual confirma por vía dinámica el defecto que el análisis estático había identificado en el bloque 6.

La verificación dinámica aportó además una precisión terminológica que conviene adoptar: la herramienta de análisis estático reporta 49 incidencias, de las cuales cuatro son advertencias y cuarenta y cinco son avisos informativos. La cifra que la bitácora del sprint venía registrando es correcta; la palabra con que se la describía, no. Tres de las cuatro advertencias corresponden a reglas de estilo retiradas del lenguaje y la cuarta a una importación sin uso en un archivo de prueba.

E. Verificación empírica del corpus

Las cifras que el proyecto reporta sobre el archivo de prueba se verificaron de forma independiente mediante conteo directo de segmentos EDI sobre el archivo, sin intervención de la aplicación. El procedimiento confirma las cifras publicadas y permite además distinguir los defectos activos de los latentes.

Tabla 66.

Verificación por conteo directo de segmentos sobre el corpus real

Magnitud	Corpus A01	Corpus A04
Contenedores (segmentos EQD+CN)	977	979
Posiciones de estiba (LOC+147)	977	979
Contenedores sin posición	0	0
Bahías distintas	27	27
Contenedores en la bahía más cargada	105	108
Fila máxima empleada	12	12
Nivel máximo empleado	90	90
Niveles de numeración impar	0	0
Coordenadas duplicadas	0	0

Magnitud	Corpus A01	Corpus A04
Bytes fuera del rango ASCII	0	0

Fuente: elaboración propia, mediante conteo directo de segmentos sobre los archivos anonimizados del corpus.

Seis de los defectos identificados no se manifiestan con estos datos y se clasifican como latentes: la pérdida de contenedores sin posición, el descarte por paridad mixta de niveles, la sobrescritura de coordenadas repetidas, la corrupción de caracteres por decodificación incorrecta, la inyección de fórmulas en la hoja de cálculo y el desbordamiento de la escala de ocupación. Siguen siendo defectos reales del código y se trasladan a las tareas de cierre, pero no producen daño con el conjunto de datos actual, y reportarlos como activos sería sobredimensionar el riesgo.

El mismo conteo, en cambio, agrava un defecto. La capacidad con que se calcula la ocupación de cada bahía supone doce filas y diez niveles. El archivo contradice el segundo supuesto: los niveles presentes son doce valores distintos que alcanzan el noventa. Comparando la ocupación mostrada contra la calculada sobre la extensión real de coordenadas de cada bahía, el promedio de las veintisiete bahías pasa de 30,2 % a 74,1 %. No se trata de una diferencia de redondeo, y afecta a una magnitud que la aplicación presenta al usuario en tres vistas distintas.

IV. Discusión

A. El valor demostrable de la redundancia

El resultado central del ejercicio no es la lista de defectos sino la medida de lo que la redundancia aportó. Tres defectos reales existen en este informe únicamente porque hubo un segundo revisor: la prueba que se satisface por vacío, el alcance sobreestimado de la regla de integridad y la violación de la separación de capas.

El primero de los tres es el más ilustrativo, porque pertenece a la clase de defectos que un revisor único no encuentra por construcción. La prueba existe, se ejecuta y se supera; quien la busque la encontrará y dará el punto por cubierto. Solo un segundo lector que examine el contenido del caso de prueba, y no su existencia, advierte que el dato que lo haría significativo falta.

B. Convergencia entre el mecanismo previsto y el síntoma observado

El resultado metodológicamente más relevante surgió de la combinación de las dos mitades. El auditor estático identificó, por lectura, que la rejilla de pantalla genera un rango continuo de niveles entre el mínimo y el máximo presentes, y comprobó sobre el corpus que ese rango abarca desde el nivel dos hasta el noventa: cuarenta y cinco filas de nivel por bahía, de las cuales solo doce contienen carga. El auditor dinámico,

sin conocer esa observación, encontró que esa misma vista detiene la aplicación en Android.

El mecanismo previsto por lectura y el síntoma observado por ejecución convergen en la misma línea de código. La relación causal no está demostrada y se enuncia como hipótesis, con un procedimiento de comprobación de dos pasos documentado en el informe de contraste. Si se confirma, la corrección es la que el generador de PDF ya aplica — calcular por separado los rangos de cubierta y de bodega— y resolvería simultáneamente la detención en Android y la divergencia entre las dos vistas.

Interesa subrayar que ninguna de las dos mitades habría llegado sola a esa conexión. La lectura identificó un derroche de representación sin poder estimar su consecuencia; la ejecución observó una falla sin poder atribuirle causa.

C. Sobre la trazabilidad de la evidencia

El contraste reveló una debilidad en el segundo informe que no afecta a sus conclusiones pero sí a su valor como evidencia. Sus veredictos resultaron sólidos —resolvió a su favor tres de las cinco discrepancias de fondo, todas sobre puntos que exigían lectura atenta del código— pero varias de sus referencias de archivo y línea no corresponden al árbol real: citan un directorio inexistente, ubican una constante en un archivo que no la contiene y atribuyen a archivos de prueba extensiones que no tienen.

La causa no es la ausencia de lectura, puesto que sus aciertos exigían haber leído, sino la reconstrucción de las referencias de memoria en lugar de su copia literal. Es la misma clase de error que la evaluación de seguridad previa documentó, aplicada esta vez a las citas y no a las conclusiones. Todas las referencias fueron verificadas contra el árbol de trabajo antes de su incorporación a este informe.

La lección operativa trasciende el caso: en un documento destinado a sustentar una evaluación académica, una referencia que no resuelve invalida ante el lector el hallazgo que la acompaña, por correcto que este sea.

D. Implicaciones para el aseguramiento de la calidad

Ninguno de los defectos identificados impide la entrega del incremento. Las cinco funcionalidades comprometidas están implementadas, las tres compilaciones de plataforma se completan y las treinta y una pruebas se superan. La detención en Android es la única con consecuencia inmediata, por afectar a una demostración en vivo, y admite dos tratamientos honestos: corregirla previa confirmación de su causa, o declararla como limitación conocida y no demostrarla.

Para el resto, el instrumento produjo una priorización que este informe adopta. Se trasladan a la tarea de revisión de calidad TC-01 la neutralización de fórmulas en la exportación, el límite de tamaño de archivo y el traslado del análisis fuera del hilo de interfaz, la corrección de

la prueba que se satisface por vacío y la separación de capas. Se traslada a la tarea de endurecimiento TC-03 la restricción de la creación de documentos de medición.

Finalmente, el ejercicio identificó un supuesto no documentado de la misma naturaleza que el límite de apilamiento ya declarado. La capacidad de cada bahía, como el límite estructural de apilamiento, no se transmite en el formato BAPLIE: reside en la documentación del buque, fuera del alcance del sistema. Corresponde declararlo con el mismo criterio con que se declaró el primero, porque la posición defendible no es que el valor sea correcto sino que la aplicación no puede derivar un dato que el formato no contiene.

V. Conclusiones

La doble revisión ciega produjo una concordancia del 83 % entre dos auditores independientes sobre 54 juicios técnicos, y quince defectos confirmados por dos vías. La concordancia sostiene que el instrumento de 78 comprobaciones es interpretable de manera consistente y que los defectos confirmados no dependen del criterio de un revisor particular.

La redundancia se justificó en términos verificables. Tres defectos reales — una prueba unitaria que se satisface sin ejercitar el caso que declara cubrir, el alcance sobreestimado de una regla de autorización y una violación de la separación de capas— existen en este informe únicamente porque un

segundo auditor revisó lo que el primero había dado por bueno. Un diseño de revisión única los habría dejado pasar.

Las dos mitades del método resultaron complementarias y no redundantes. La revisión estática previó un mecanismo de representación excesiva que no podía medir; la verificación dinámica observó una detención de la aplicación a la que no podía atribuir causa; ambas convergen en la misma línea de código sin que ninguno de los dos auditores conociera el trabajo del otro.

El contraste con los datos reales permitió distinguir seis defectos latentes de los activos, evitando sobredimensionar el riesgo, y agravó en cambio un séptimo: la ocupación que la aplicación presenta se calcula sobre una capacidad supuesta que el propio archivo contradice, con una diferencia media de 30,2 % frente a 74,1 %. Ese supuesto se incorpora a las limitaciones declaradas del sistema.

El incremento se considera entregable. Los defectos identificados quedan priorizados y asignados a las tareas de cierre TC-01 y TC-03, con la única excepción de la detención en Android, cuyo tratamiento debe decidirse antes de la revisión del incremento.

Corresponde por último precisar el alcance de lo que aquí se concluye. No se afirma que el producto esté libre de defectos ni que la revisión haya sido exhaustiva: se afirma que dos auditores independientes aplicaron un instrumento declarado por adelantado, que su grado de acuerdo es medible, y

que las discrepancias entre ambos fueron resueltas contra el código y no por consenso.

VI. Referencias

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2010). Metodología de la investigación (5.^a ed.). McGraw-Hill.

MITRE Corporation. (s. f.). CWE-1236: Improper neutralization of formula elements in a CSV file. Common Weakness Enumeration.
<https://cwe.mitre.org/data/definitions/1236.html>

OWASP Foundation. (2024). OWASP Mobile Top 10 2024 – Final release.
<https://owasp.org/www-project-mobile-top-10/2023-risks/>

OWASP Foundation. (2025). OWASP Top 10:2025 – The ten most critical security risks to web applications. <https://owasp.org/Top10/2025/>

Schwaber, K., & Sutherland, J. (2020). The Scrum Guide: The definitive guide to Scrum – The rules of the game. Scrum.org.